

Istraživanje podataka 1 - vežbe 12

1 Pravila pridruživanja

1.1 Skupovi stavki u transakcijama

Skup podataka u kome se traže pravila pridruživanja se sastoji od transakcija. Dakle, jedna instanca skupa podataka je jedna transakcija. Jednu transakciju čine stavke koje se pojavljuju zajedno. Npr. ako skup podataka sadrži podatke o kupovini voća na pijaci, jedna transakcija je jedna kupovina jednog kupca. Primer skupa podataka je dat u tabeli 1.

Id transakcije	Stavke u transakciji
1	$\{Jabuke, Lubenica, Maline\}$
2	$\{Jabuke, Maline\}$
3	$\{Jabuke, Banane\}$
4	$\{Jabuke, Banane\}$
5	$\{Banane\}$
6	$\{Banane, Lubenica, Maline\}$

Tabela 1: Primer skupa podataka koji sadrži podatke o kupovini voća na pijaci. Jedna transakcija je jedan red u tabeli.

Skup stavki (eng. *itemset*) sadrži jednu ili više stavki transakcije. Skup stavki koji sadrži k stavki naziva se k -skup stavki.


Bitno svojstvo skupa stavki je podrška (eng. *support*). Ako je ukupan broj transakcija u skupu N , a $\#(X)$ broj transakcija koje sadrže skup stavki X , podrška skupa stavki X se računa kao

$$sup(X) = \frac{\#(X)}{N}$$

Na primer, podrška za skup stavki $\{Jabuke, Banane\}$ u skupu iz tabele 1 je $\frac{2}{6}$.

Skup stavki X za koji važi $sup(X) \geq min_{sup}$ se naziva **čest skup stavki**. Vrednost min_{sup} je minimalna podrška koju zadaje korisnik.

Za pregledan način prikazivanja svih mogućih skupova stavki koje se pojavljuju u skupu podataka koirsti se *rešetka*. Skupovi stavki su podeljeni u $n + 1$ nivoa, gde je n broj stavki koje se javljaju u skupu. Nivoi su obeleženi od 0 do n . Na nivou k se predstavljaju k -skupovi stavki. 0-skup stavki je prazan skup, 1-skupovi stavki sadrže po jednu stavku, a n -skup stavki sadrži sve stavke koje se javljaju u skupu podataka. Skup stavki na nivou k je povezan sa svojim nadskupovima na nivou $k + 1$. Na slici 1 je prikazana rešetka sa skupovima stavki za skup podataka iz tabele 1.



Slika 1: Prikaz skupova stavki za skup podataka dat u tabeli 1 preko *rešetke*

1.2 Pravila pridruživanja u skupu podataka

Pri određivanju pravila pridruživanja u skupu podataka traže se pravila oblika:

$$telo \rightarrow glava$$

gde su *telo* i *glava* skupovi stavki. Pravilo se čita sa: *Ako se u transakciji pojave stavke iz tela, verovatno će se pojaviti i stavke iz glave.*

Na primer, pravila mogu biti $Jabuke \rightarrow Banane$ ili $\{Jabuke, Mailine\} \rightarrow Lubenica$.

Osnovne mere za određivanje kvaliteta pravila pridruživanja su:

- Podrška (eng. *support*) : $sup(X \rightarrow Y) = \frac{\#(X \cup Y)}{N}$
- Pouzdanost (eng. *confidence*): $conf(X \rightarrow Y) = \frac{\#(X \cup Y)}{\#(X)}$

Podrška određuje koliko se često pravilo pojavljuje u transakcijama skupa podataka, dok pouzdanost određuje koliko se često stavke iz Y pojavljuju u transakcijama koje sadrže stavke iz X .

Za dati skup transakcija cilj je izdvojiti pravila pridruživanja koja imaju:

- podršku $\geq min_{sup}$
- pouzdanost $\geq min_{conf}$

Minimalni prag podrške min_{sup} i minimalni prag pouzdanosti min_{conf} zadaje korisnik.

Najjednostavniji način za određivanje pravila pridruživanja je (1) izdvajanje svih mogućih pravila pridruživanja, (2) računanje podrške i pouzdanosti za svako izdvojeno pravilo i (3) poređenje dobijenih vrednosti sa zadatim pragovima. Međutim, pristup grube sile za određivanje pravila pridruživanja je izuzetno skup zbog velikog broja pravila koja se mogu izdvojiti iz skupa.

Da bi se smanjio broj potrebnih izračunavanja, koristi se svojstvo da je $sup(X \rightarrow Y) = sup(X \cup Y)$, pa se prvo izdvajaju česti skupovi stavki, a zatim se za svaki čest skup stavki prave moguća pravila i proverava koje pravilo ima zadovoljavajuću pouzdanost. Npr. za skup stavki $\{Jabuke, Mailine, Lubenica\}$ moguća pravila (sa uslovom da ni glava ni telo nisu prazan skup) su:

$\{Jabuke\} \rightarrow \{Mailine, Lubenica\}$
 $\{Mailine\} \rightarrow \{Jabuke, Lubenica\}$
 $\{Lubenica\} \rightarrow \{Jabuke, Mailine\}$
 $\{Jabuke, Mailine\} \rightarrow \{Lubenica\}$
 $\{Jabuke, Lubenica\} \rightarrow \{Mailine\}$
 $\{Mailine, Lubenica\} \rightarrow \{Jabuke\}$

Zbog toga se algoritam *Apriori*, a i drugi, za određivanje pravila pridruživanja sastoji iz dve faze:

1. Generisanje čestih skupova stavki
2. Generisanje pravila pridruživanja na osnovu izdvojenih čestih skupova stavki


1.3 Apriori algoritam

Jedan od najpoznatijih algoritama za izdvajanje pravila pridruživanja je Apriori algoritam. Apriori algoritam u fazi generisanja čestih skupova stavki koristi osobine podrške kako bi se smanjio broj skupova stavki za koje je potrebno izračunati podršku da bi se odredilo da li je skup stavki čest. Algoritam za smanjenje kandidatskih skupova stavki za koje je potrebno izračunati podršku koristi:

- princip: *Ako je skup čest, onda i svi njegovi podskupovi moraju biti česti.*
- anti-monotonost podrške: $\forall X, X \subset Y : sup(Y) \leq sup(X)$

Na primer, ako je skup stavki $\{Jabuke, Mailine, Lubenica\}$ čest, onda su česti i skupovi stavki $\{Jabuke, Mailine\}$, $\{Jabuke, Lubenica\}$, $\{Mailine, Lubenica\}$, $\{Jabuke\}$, $\{Mailine\}$, $\{Lubenica\}$, jer u svakoj transakciji u kojoj se pojavljuje skup stavki $\{Jabuke, Mailine, Lubenica\}$, pojavljuje se i svaki od njegovih podskupova.

Takođe važi i obrnuto - ako neki od podskupova skupa stavki nije čest, onda ni skup stavki ne može biti čest. Na primer, ako podskup $\{Mailine, Lubenica\}$ nije čest, tj. podrška mu je manja od zadatog praga, onda ni skup stavki $\{Jabuke, Mailine, Lubenica\}$ ne može biti čest, kao ni bilo koji drugi nadskup skupa stavki $\{Mailine, Lubenica\}$. Na slici 2 je preko rešetke označen skup stavki $\{Mailine, Lubenica\}$ plavom bojom, a crvenom bojom svi njegovi nadskupovi za skup transakcija dat u tabeli 1.



Slika 2: Prikaz nadskupova skupa stavki $\{Mailine, Lubenica\}$ preko rešetke za skup podataka iz

U algoritmu 1 su dati koraci za generisanje čestih skupova stavki u Apriori algoritmu.

Algoritam 1: Generisanje čestih skupova stavki u Apriori algoritmu

1 : Identifikacija skupova stavki dužine 1 koji su česti.

2 : Za k od 2 do n , gde je n broj stavki u skupu podataka izvršiti:

2.1 : Generisanje kandidata

- Generisanje kandidata dužine k (skup stavki dužine k) na osnovu $k - 1$ čestih skupova stavki - spajanjem dva česta skupa stavki dužine $k - 1$ za koje važi da se prvih $k - 2$ stavki poklapaju kada su im stavke sortirane leksikografski.

2.2 : Čišćenje kandidata

- Eliminisanje k skupova stavki iz kandidata ako važi da postoji neki podskup dužine $k - 1$ koji nije čest.
 - Računanje podrške za preostale kandidate i eliminisanje kandidata dužine k čija je podrška manja od sup_{min}
-

1.4 Mere kvaliteta pravila pridruživanja

Za računanje kvaliteta pravila pridruživanja, pored podrške i pouzdanosti, mogu se koristiti:

- **lift mera:** $Lift(X \rightarrow Y) = \frac{conf(X \rightarrow Y)}{sup(Y)}$ ili $Lift = \frac{conf_{posterior}}{conf_{prior}}$

* Pravilo $X \rightarrow Y$ je zanimljivo ako je $Lift(X \rightarrow Y) \neq 1$.

Na primer, ako je $conf(X \rightarrow Y) = 0.4$ (u 40% transakcija u kojima se javlja X , javlja se i Y), a i $sup(Y) = 0.4$ (u 40% transakcija u skupu podataka javlja se Y), vrednost mere $Lift$ je 1. Zaključak je da pravilo $X \rightarrow Y$ nije interesantno, jer se Y ne pojavljuje ni češće ni ređe u transakcijama koje sadrže X nego u celom skupu transakcija. Ako je $Lift > 1$, tada se Y pojavljuje u transakcijama koje sadrže X više od očekivanog broja pojavljivanja, a ako je $Lift < 1$, Y se pojavljuje u transakcijama koje sadrže X manje od očekivanog broja pojavljivanja, što takođe može biti interesantno. Za izdvajanje zanimljivih pravila prema $Lift$ meri može se postaviti uslov da se izdvoje pravila za koja važi da vrednost $Lift$ mere nije u opsegu od npr. $[0.95, 1.1]$.

- **mogućnost raspoređivanja:** $Deployability(X \rightarrow Y) = \frac{\#(X) - \#(X \cup Y)}{N}$

1.5 Zadaci

1. Nacrtati rešetku skupova stavki koja odgovara skupu podataka datom u tabeli 1. Označiti čvorove u rešetki sledećim slovima:


- **N** - ako se skup stavki ne smatra kandidatom po Apriori algoritmu, odnosno u sledećim slučajevima:
 - 1) skup stavki nije generisan u koraku generisanja kandidata
 - 2) skup stavki je generisan u koraku generisanja kandidata ali je kasnije uklonjen u koraku čišćenja kandidata jer neki njegov podskup nije čest
- **F** - kandidat skupa stavki je čest po Apriori algoritmu
- **I** - ako se skup stavki smatra retkim posle određivanja podrške

Minimalna podrška za česte skupove je 0,3.


Rešenje

Pošto je $min_{sup} = 0.3$, a skup podataka sadrži ukupno 6 transakcija, skupovi stavki koji se pojavljuju u bar 2 transakcije su česti. Pored svakog čvora u rešetkama koje su deo rešenja je u gornjem desnom uglu označeno da li je pridruženi skup podataka čest (F), nije čest ali je bilo neophodno prebrojavanje u koliko transakcija se javlja jer su mu svi podskupovi česti (I), ili nije čest i nije bilo potrebno računati u koliko transakcija se javlja jer mu bar jedan podskup nije čest (N). U donjem levom uglu čvora je ispisan broj transakcija u kojima se javlja pridruženi skup stavki ukoliko je bilo potrebno izračunati tu vrednost.

Prvo se za 1-skupove stavki prebrojava u koliko transakcija se pojavljuju i za svaki 1-skup stavki određuje da li je F ili I .






Pošto su svi 1-skupovi stavki česti, za svaki 2-skup stavki se mora izračunati broj transakcija u kojima se javlja da bi se odredilo da li je skup čest ili ne.




Za 2-skupove stavki koji nisu česti (označeni sa I) mogu se odmah pronaći svi nadskupovi i oz-

načiti kao retki, bez računanja broja transakcija u kojima se javljaju. Na narednim rešetkama je po jedan nečest 2-skup stavki označen plavom bojom, a crvenom bojom njegovi nadskupovi za koje se zna da nisu česti bez računanja broja transakcija u kojima se javljaju i koji mogu da se označe sa N .



Pošto svaki 3-skup stavki ima podskup koji nije čest, ni on sam ne može biti čest. Isto važi i za 4-skupove stavki. Rešetka sa pridruženim oznakama za svaki čvor izgleda:




2. Nacrtati rešetku skupova stavki koja odgovara datom skupu podataka. Označiti čvorove u rešetki na isti način kao u prethodnom zadatku.

Transaction ID	Items Bought
1	{a, b, d, e}
2	{b, c, d}
3	{a, b, d, e}
4	{a, c, d, e}
5	{b, c, d, e}
6	{b, d, e}
7	{c, d}
8	{a, b, c}
9	{a, d, e}
10	{b, d}

Minimalna podrška za česte skupove je 0, 3.

- Koliki je procenat čestih skupova stavki?
- Koliki je odnos čišćenja Apriori algoritma za ovaj skup podataka? Odnos čišćenja je definisan kao procenat skupova stavki koji nisu generisani za vreme generisanja kandidata ili su eliminisani u koraku čišćenja kandidata.
- Koliki je odnos lažnog alarma (procenat kandidatskih skupova stavki koji su obeleženi kao retki posle prebrojavanja podrške)?

Rešenje



Odgovori na pitanja iz zadatka:

- $\frac{16}{32} = 50\%$
- $\frac{11}{32} = 34.4\%$
- $\frac{5}{32} = 15.6\%$